Ingeniería de soluciones con AI

Semestre 2026-1

Docente:

Francisco Macaya

¿Quién soy?

Francisco Macaya

- Ingeniero Civil Industrial de la Federico Santa María
- Magister en Inteligencia Artificial en la PUC.
- Candidato a Magister en ciencia de la computación en Birkbeck, Universidad de Londres.
- Tutor en la Universidad de Montevideo para la carrera de Data Science.
- Experiencia como Líder y Data Scientist en la industria financiera y retail. (SMU, Grupo Security y Vida Camara).

Estoy afuera de Chile, así que estoy adelantado en tres horas respecto a ustedes.

En tecnología, lo permanente es el constante ***cambio****.*

Temario del semestre

El semestre constará de las siguientes secciones:

1- Fundamentos de AI Generativa y Prompt Engineering.

2- Desarrollo de Agentes Inteligentes con AI.

3- Observabilidad, Seguridad y ética de Agente de AI.

Evaluaciones: Cada uno de estas secciones tendrá una ***evaluación***, junto con el ***examen final*** del curso.

Noticias: *El mercado no esta destruido.*

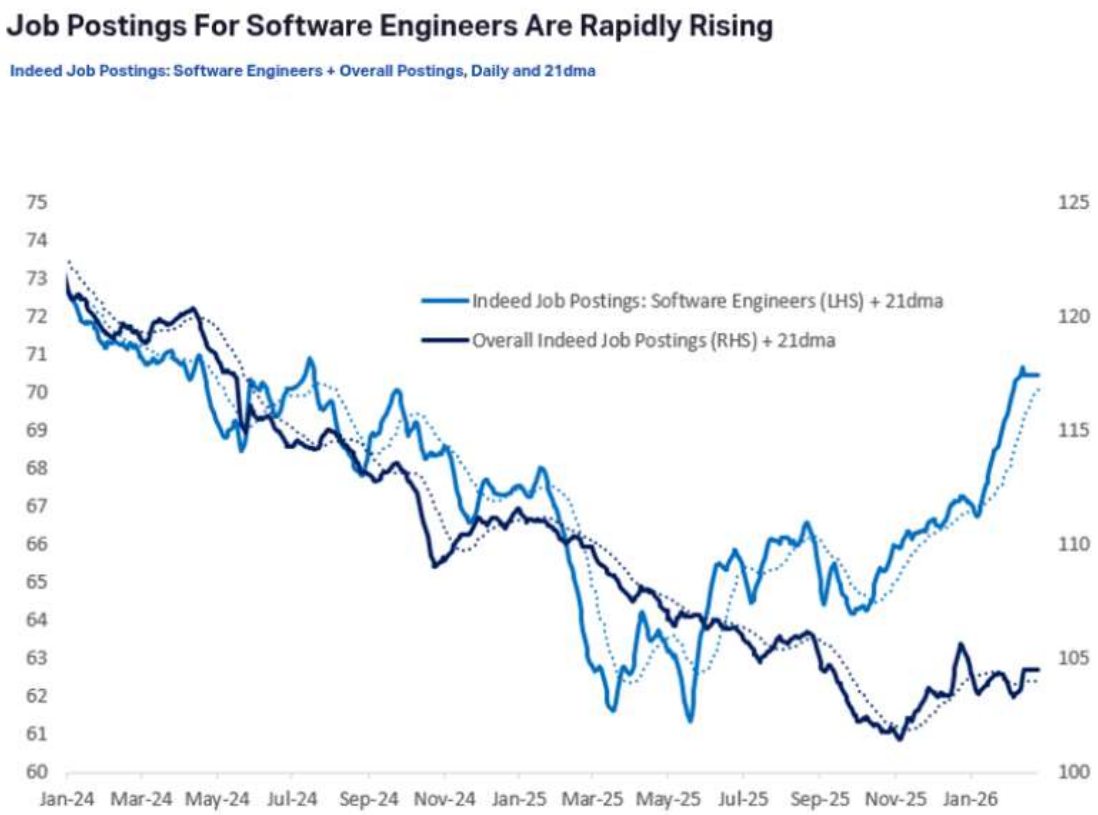

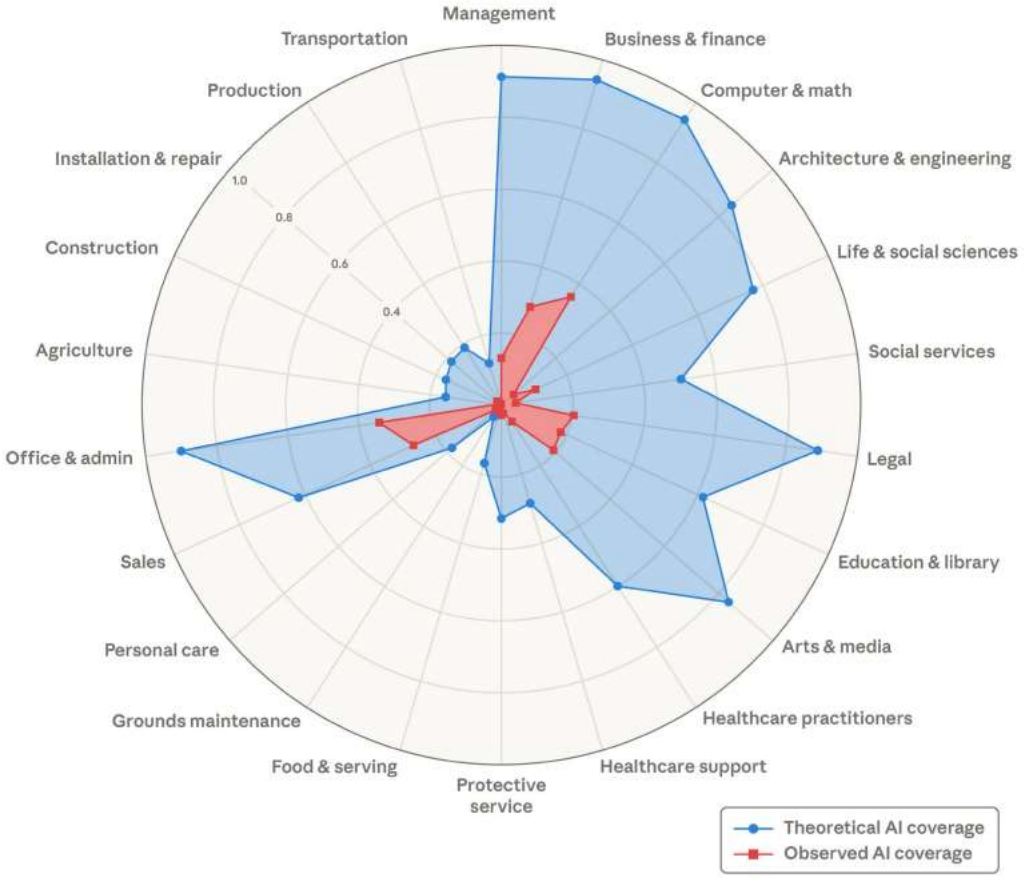

Figure 2: Theoretical capability and observed exposure by occupational category
This figure shows the share of job tasks that LLMs could theoretically perform (blue area) and our own job coverage measure derived from usage data (red area).

Nota: https://www.anthropic.com/research/labor-market-impacts

Historia: Deep Learning

1939-1945

Alan Turing design and build the first computer during the Second World War

1982

John Hopfield introduce a Hopfield Newtwork, recurrent neural network that server as associative memory

1986

Geoffrey Hinton, David Rumelhart, and Ronald Williams develop backpropagation, making the training of multi-layered neural networks feasible

1990

Yann LeCun pioneers Convolutional Neural Networks (CNNs), laying the groundwork for modern computer vision

2006

Fei-Fei Li begins creating ImageNet, a massive labeled visual dataset to advance machine learning.

2012

AlexNet, created by Alex Krizhevsky and co-supervised by Geoffrey Hinton, wins the ImageNet Challenge, demonstrating the power of deep learning.

2015

Elon Musk, Sam Altman, Greg Brockman, and others co-found OpenAI to promote safe and open AI development.

2016

AlphaGo defeated the world champion of Go in 2016. Lee Sedol

2017

Google researchers introduce the Transformer architecture with the paper "Attention is All You Need," revolutionizing NLP and leading to models like BERT and GPT.

2022

OpenAI launched ChatGPT in Novembre of 2022.

¿Qué paso aquí?

¿Qué es ChatGPT?

¿Qué es ChatGPT?

Es un chat construido por la compañía OpenAI basado en la arquitectura GPT ***(Generative Pre–Trained Transformer).***

¿Estamos haciendo algo?

Primer Large Lenguaje model entrenado con un corpus de Latinoamerica. Se entrenó con 2.645.000 documentos, siendo Brasil y México los países con la mayor cantidad de datos suministrados. El presupuesto del proyecto fue de $550.000 dólares.

https://www.latamgpt.org/

¿Inversión o gasto publico?

Fundamentos: ***Deep Learning***

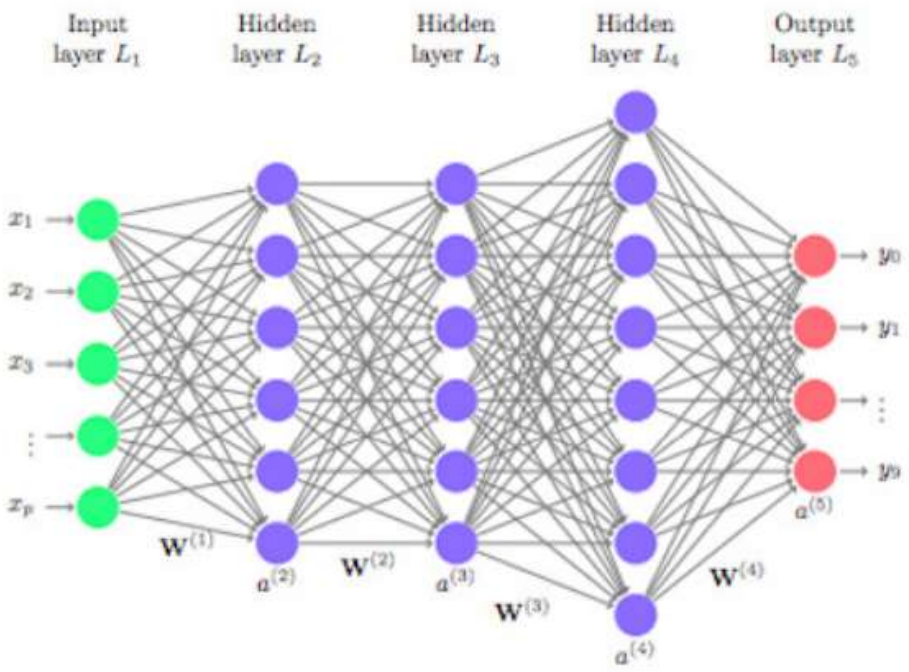

Image: UC Business Analytics R Programming Guide

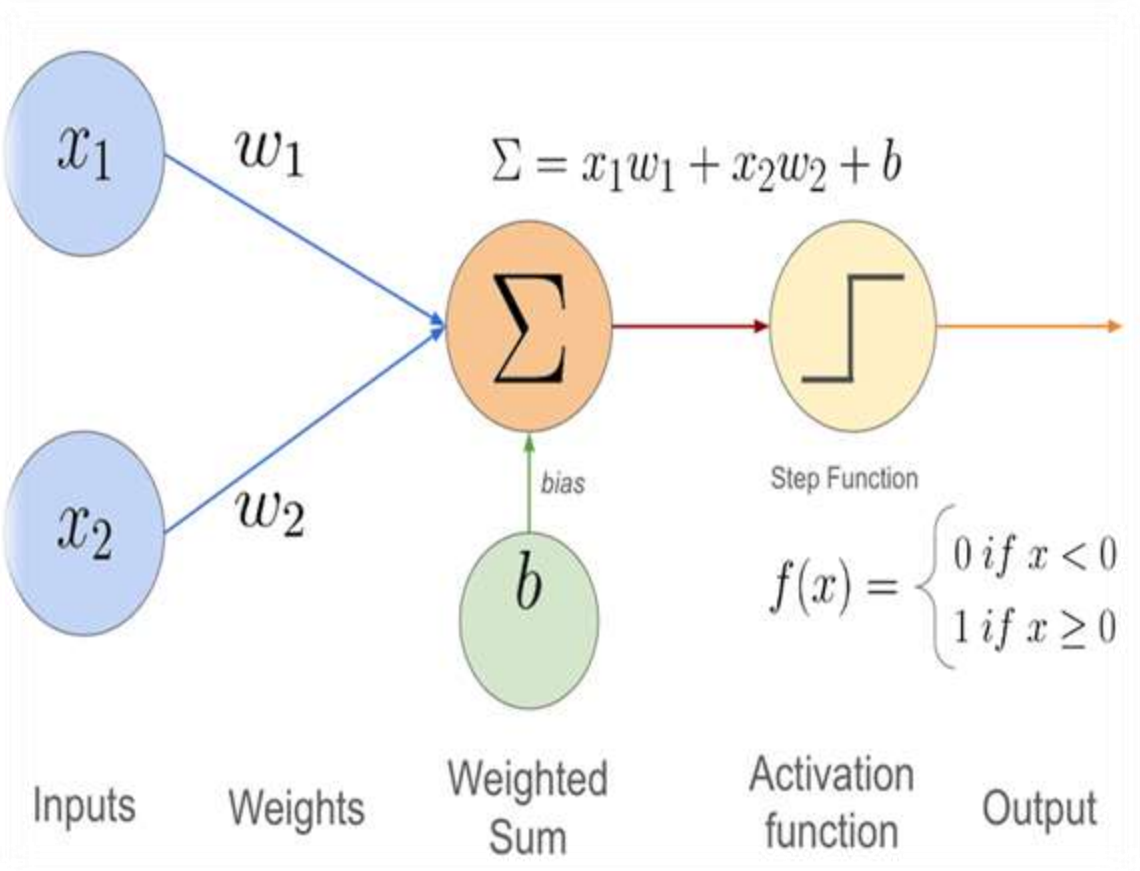

Los principales conceptos de las redes neuronales son inputs, layers, weights, funciones de activaciones y optimizaciones. Es una compleja arquitectura que logra encontrar patrones desde sus datos de entrenamiento.

*Antes de "transformers": **RNN, LSTM y GRU***

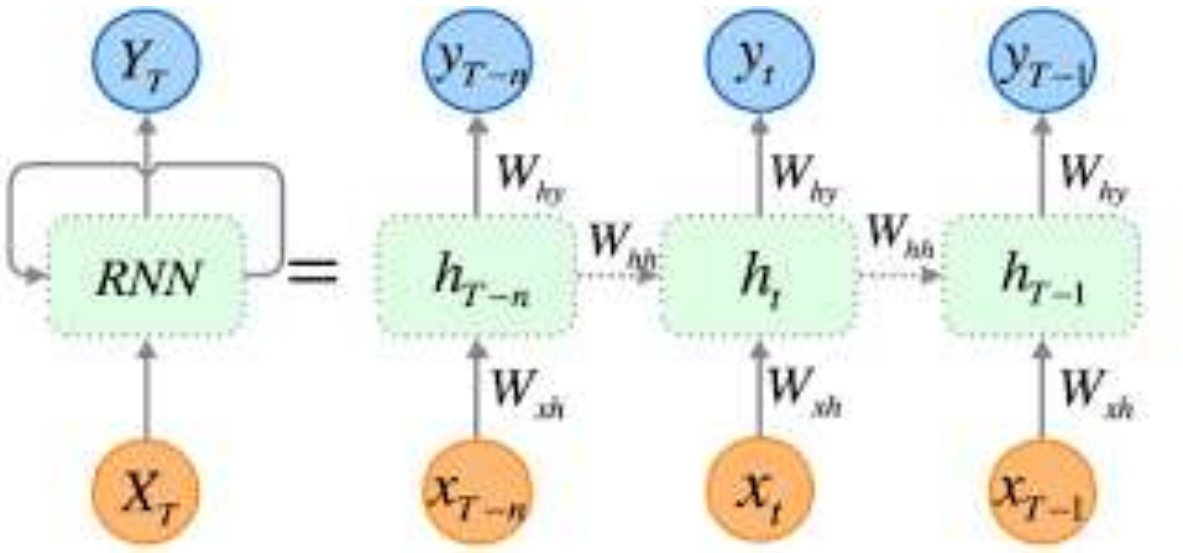

Hola, como estas?
Hola → estado₁ (Función de Activación)
estado₁ + cómo → estado₂ (Función de activación)
estado₂ + estás → estado₃

El modelo ya paso por dos funciones de activación, y multiplicaciones matriciales antes de llegar al estado 3. No obtiene directamente el "hola".

*The animal didn't cross the street because **it** was too tired.*

↓

Las arquitecturas tenían problemas para captar dependencias anteriores.

Sus **principales problemas** eran:

- Dificultad para capturar dependencias largas.
- Entrenamiento lento.
- Problema de vanishing gradient.
- Contexto limitado.

Breakpoint: Attention Is All You Need

Provided proper attribution is provided, Google hereby grants permission to reproduce the tables and figures in this paper solely for use in journalistic or scholarly works.

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com

Noam Shazeer* Google Brain noam@google.com

Niki Parmar* Google Research nikip@google.com

Jakob Uszkoreit* Google Research usz@google.com

Llion Jones* Google Research llion@google.com

Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu

Łukasz Kaiser* Google Brain lukaszkaiser@google.com

Illia Polosukhin* ‡ illia.polosukhin@gmail.com

cs.CL] 2 Aug 2023

Self-attention: captura y mira directamente todas las palabras.

El paper “Attention Is All You Need”, publicado por Ashish Vaswani, Noam Shazeer, Niki Parmar y otros investigadores de Google, introdujo la arquitectura Transformer.

Los beneficios son:

- Capturar dependencias largas.
- Todas las palabras se analizan al mismo tiempo. (mejor uso de GPU).
- Mejor compresión del texto.
- Escala mejor con modelos con más parámetros.

Nota: https://arxiv.org/pdf/1706.03762

¿Qué son los *Transformers*?

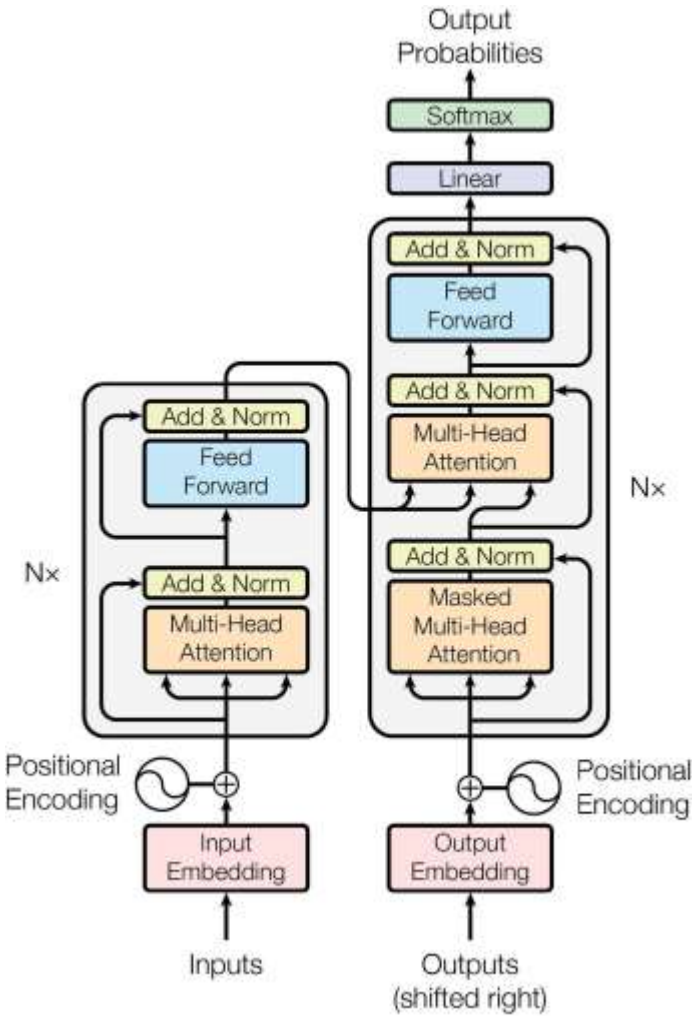

Es un tipo de arquitectura de red neuronal diseñada para trabajar con secuencias de datos.

El diseño de esta arquitectura es importante porque permite predecir el siguiente "token" considerando no solo la última palabra, sino también el contexto formado por todas las palabras anteriores.

La arquitectura en simple funciona de la siguiente manera:

1- **Input Embedding:** Palabra a vector numérico.
2- **Positional Encoding** posición de las palabras en la frase.
3- **Self-Attention:** Cada palabra calcula su importancia respecto a cada otra palabra.
4- **Feed Forward Network**: Se procesan vectores para aprender patrones más complejos.
5- **Output Layer:** modelo predice el siguiente **token.**

Nota: https://arxiv.org/pdf/1706.03762

El objetivo de esta arquitectura es predecir la próxima ***palabra****.*

El objetivo de esta arquitectura es predecir el próximo ~~***palabra***~~*.* ***token***

¿Qué son los *tokens*?

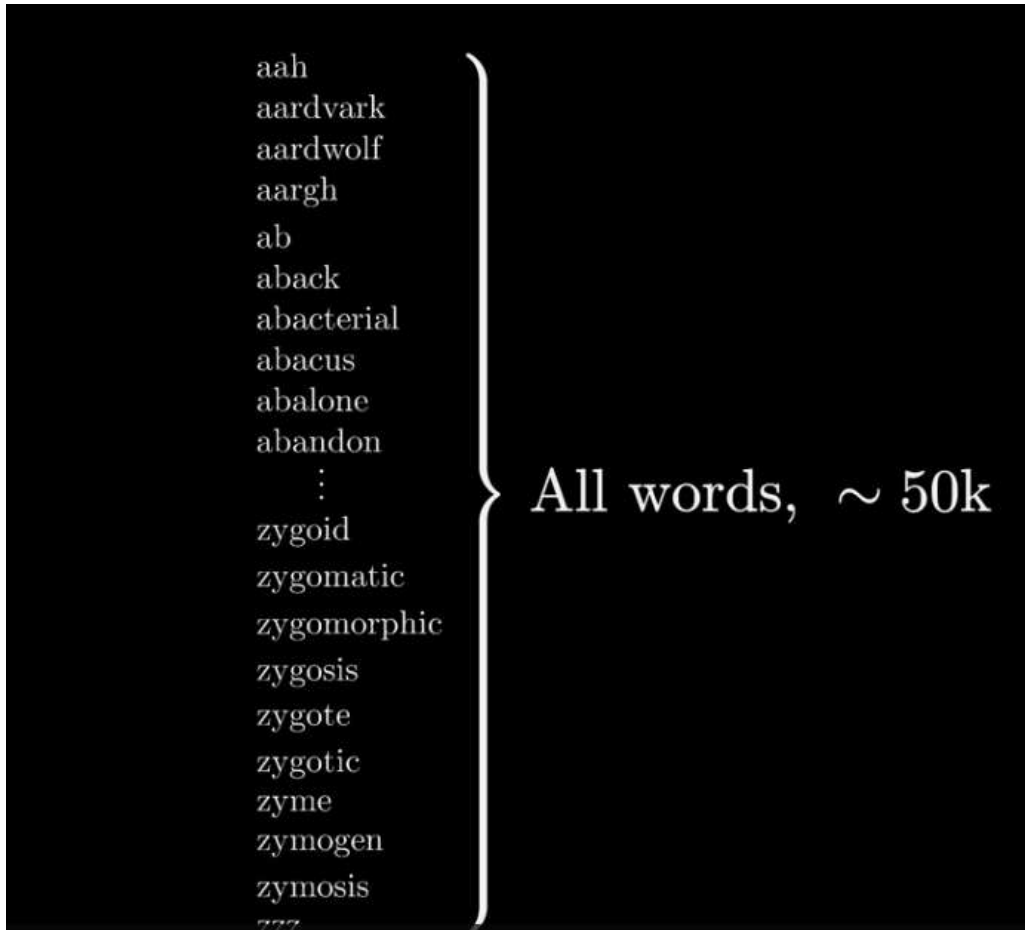

Los computadores no procesan palabras, sino que procesan números. (representaciones binarias).

Los tokens es el conjunto de “palabras” que hay en el conjunto de los datos de entrenamiento del modelo.

Ejemplo: Hola, como estas?
Lista de Tokens: [“Hola”, “,como”, “estas?”]

El input del usuario se divide en tokens mediante un tokenizador. Luego se buscan los IDs de esos tokens y cada ID se transforma en un embedding.

Los tokens forman parte central del modelo de negocio de los LLMs, ya que cada consulta realizada a estos sistemas se cobra considerando tanto los tokens de entrada (prompt tokens) como los tokens de salida (completion tokens).

Nota: *https://www.youtube.com/watch?v=wjZofJX0v4M&t=183s*

¿Qué son los *Embeddings*?

Los embeddings son vectores de números que representan el significado de palabras, frases o documentos para que un computador pueda procesarlos.

Los embeddings son importantes por el propio modelo, y por otras técnicas, tales como: ***RAG. (Retrieval-Augmented Generation).***

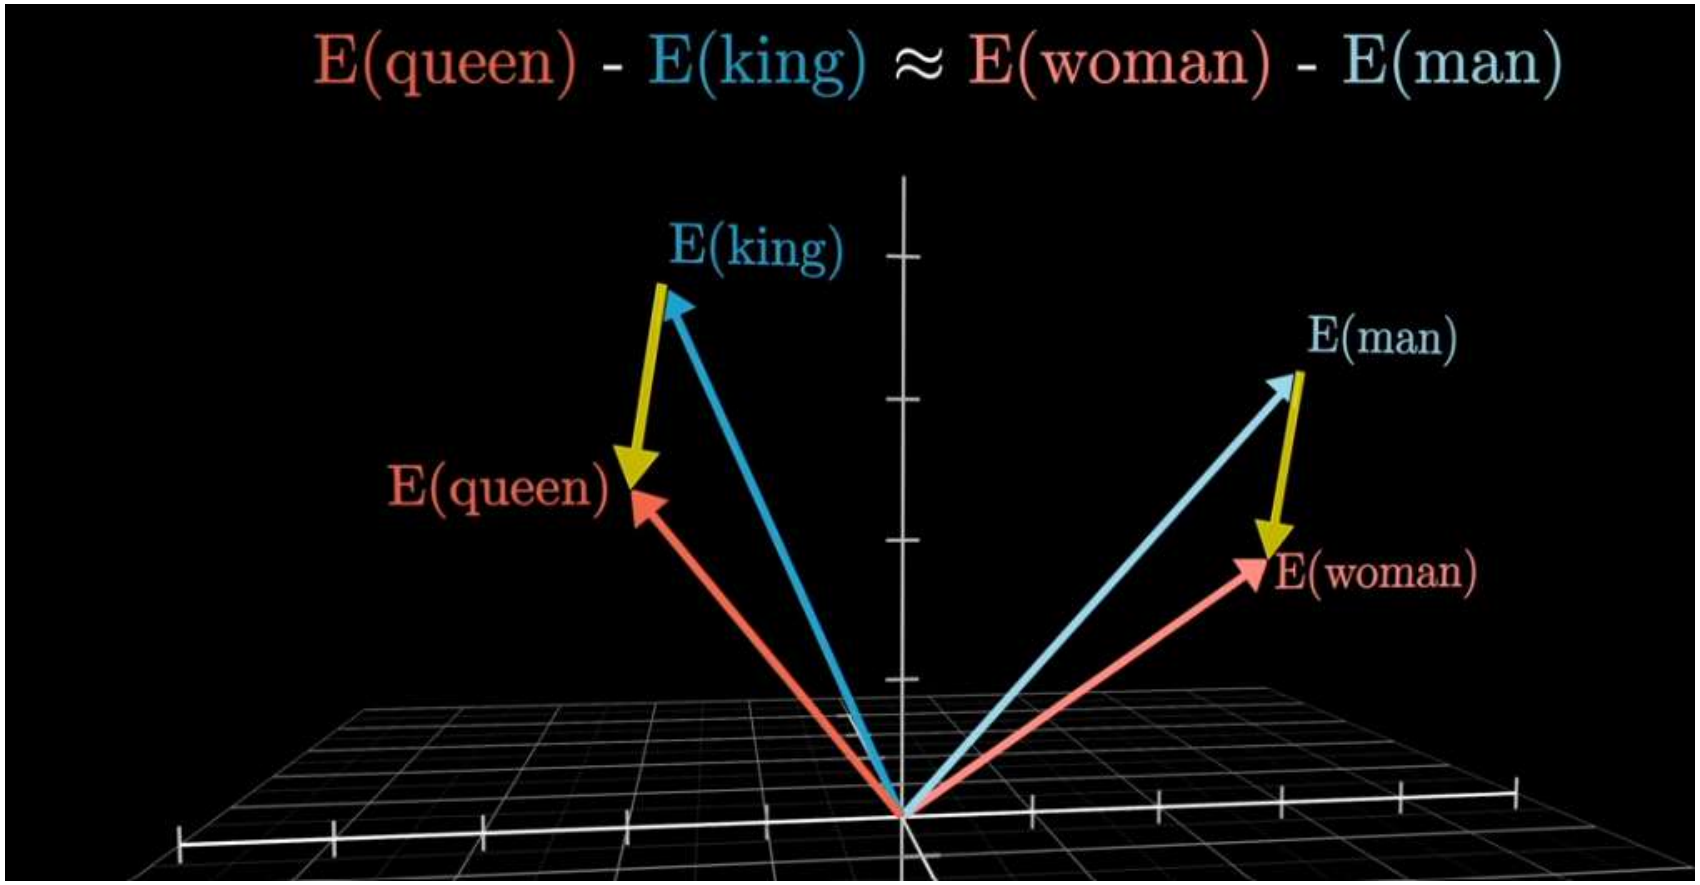

Nota: *https://www.youtube.com/watch?v=wjZofJX0v4M&t=183s*

Temperatura: *Descontrolemos las probabilidades*

T = 0

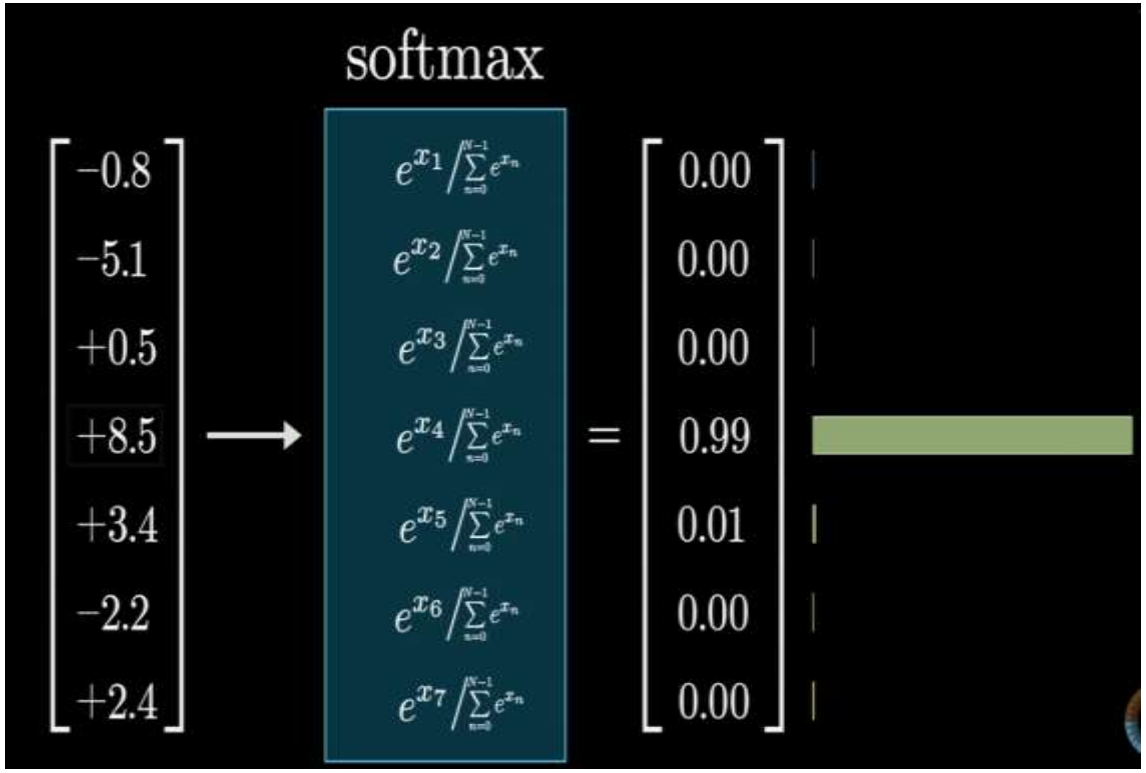

T = 10

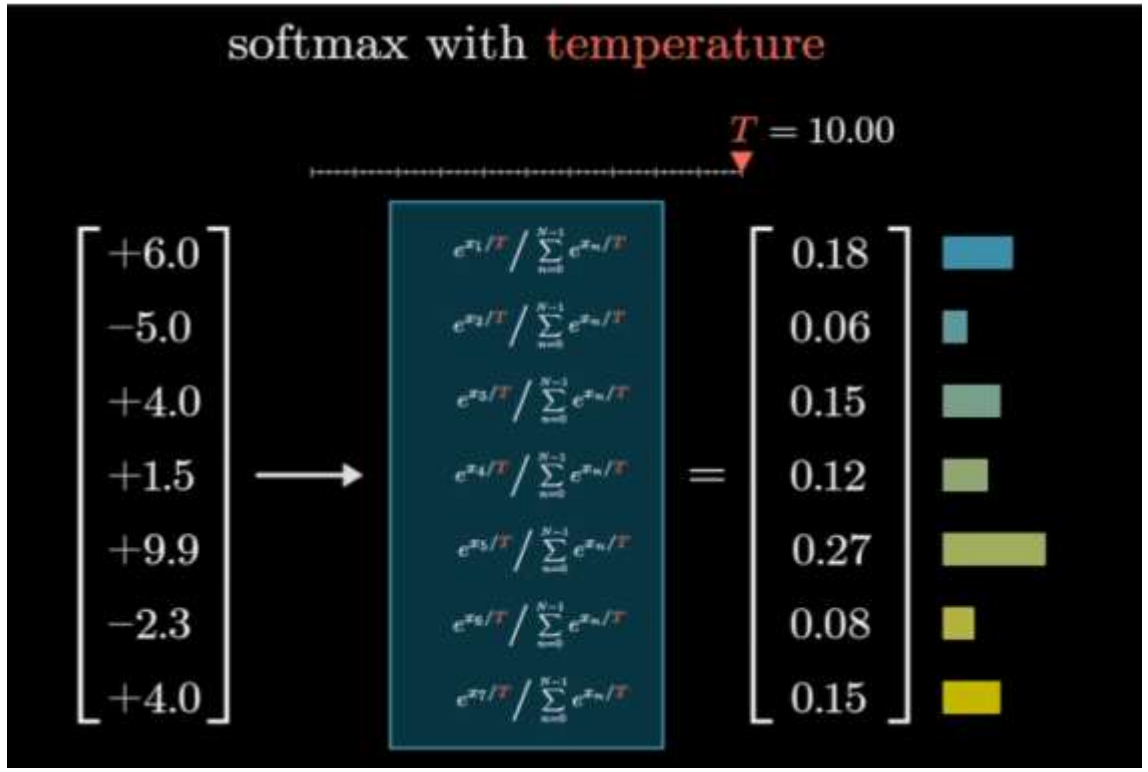

La temperatura *es el parámetro para regulizar la distribuciones de probabilidad de la salida. A mayor t, la distribución se aplana, entonces el resultado de la salida será más uniforme (más aleatorio). En términos simples, si quiero que el modelo me de una respuesta menos determinista, entonces aumento el t, sino viceversa.*

Nota: *https://www.youtube.com/watch?v=wjZofJX0v4M&t=183s*

Parámetros de los LLMs: Más que la temperatura.

Parámetro	Para qué sirve
temperature	Controla el nivel de creatividad o aleatoriedad del modelo.
max_tokens	Define el límite máximo de tokens que el modelo puede generar en la respuesta.
top_p	Controla la diversidad probabilística usando nucleus sampling.
top_k	Limita la selección a los k tokens más probables en cada paso.
frequency_penalty	Reduce repeticiones penalizando palabras que aparecen con mucha frecuencia.
presence_penalty	Incentiva la aparición de nuevas palabras o temas en la respuesta.

¿Cuáles son las empresas detrás de los foundation models?

¿Cuáles son las empresas detrás de los foundation model?

Mark Zuckerberg.
Meta

Dario Amodei
Founder/CEO Anthropic

Sam Altman
OpenAI

Demis Hassabis.
Google DeepMind
AlphaFold
Premio Nobel de Química 2024

¿Cómo ha sido la evolución en los últimos tres años?

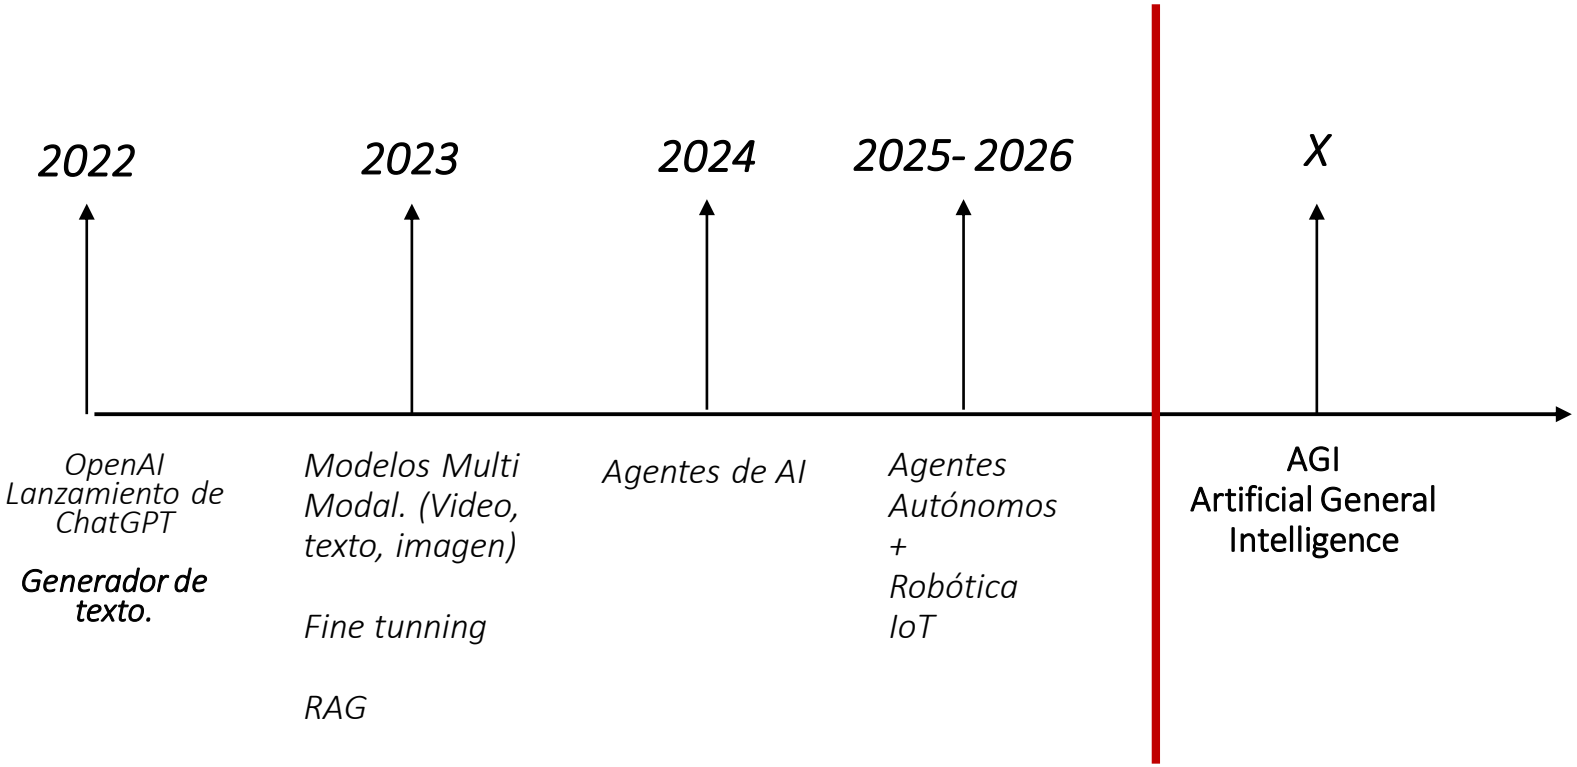

¿Dónde aprender?: Mucho ruido

- *En clases. Aprovechen de preguntar. Sino lo se, lo intentaré averiguar, y volveré con ustedes.*
- *Vean Anthropic, deeplearning, langchain, Harvard review papers, MIT, o'Reilly, papers.*
- *Júntense con personas. (compañeros, comunidades).*
- *Conózcanse, y sepan como ustedes aprenden mejor.*
- *Construyan cosas que les importen.*

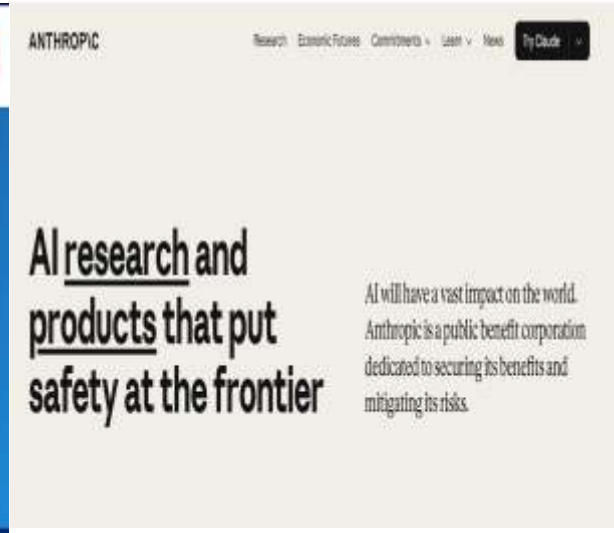

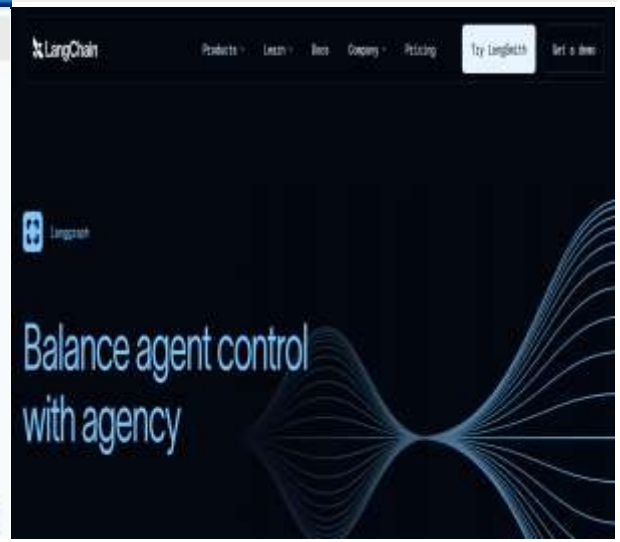

Lab N°1.1: Groq como proveedor de LLMs

En este laboratorio practico, se utilizará los modelos de Groq, que es una empresa que optimiza la inferencia de modelos de lenguaje opensource. Las instrucciones son las siguientes:

1- Acceder a esta pagina: https://groq.com/.
2- Crear una cuenta con Google login.
3- Acceder a la sección "API Keys".
4- Apretar el botón "Create API Key".
5- Crear la API KEY, y guárdala para almacenarla en el notebook.